Eficiência Energética

Relatório de Modelagem Estatística

João Ivo Rocha Alves — Matrícula **581734**

Juan Bryan Araújo Lima — Matrícula **581552**

Kaleb Soares Souza — Matrícula **581511**

Fonte dos dados: UCI Machine Learning Repository — Energy Efficiency.
Tsanas e Xifara (2012), *Accurate quantitative estimation of energy performance of residential buildings using statistical machine learning tools*, publicado em *Energy and Buildings*.

Pergunta de pesquisa e objetivo

Motivação e Pergunta Central

Como as características geométricas e construtivas das edificações estão associadas às suas demandas energéticas?

A eficiência energética é crucial para a sustentabilidade urbana e redução de custos operacionais.

Objetivos Estatísticos

Construir e comparar modelos de Regressão Linear Múltipla para as respostas:

- Y_1: Heating Load (Demanda de Aquecimento)
- Y_2: Cooling Load (Demanda de Resfriamento)

Etapas do Projeto

1. Análise Exploratória e Diagnóstico de Colinearidade
2. Seleção de Modelos de Referência (MQO)
3. Diagnóstico dos Resíduos e Avaliação de Especificações Alternativas

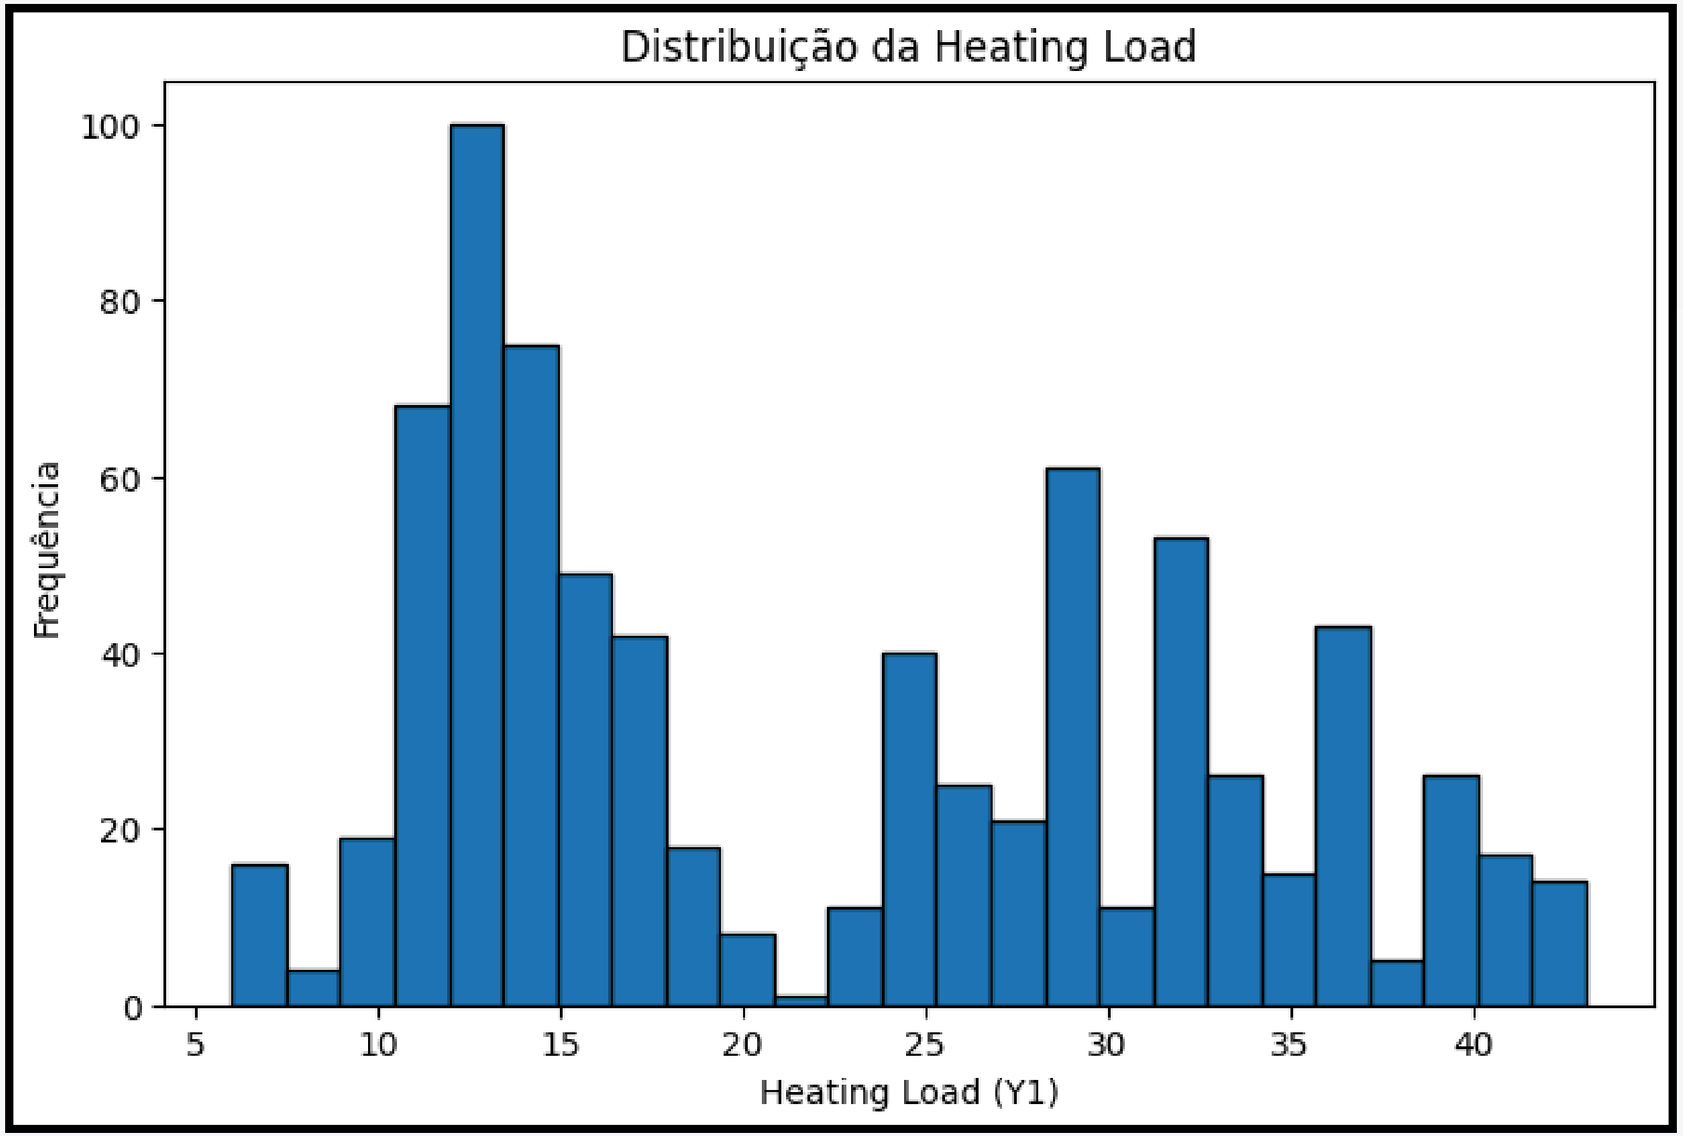
Conhecendo os dados

768	8	2	0
OBSERVAÇÕES	EXPLICATIVAS (X)	RESPOSTAS (Y)	VALORES AUSENTES

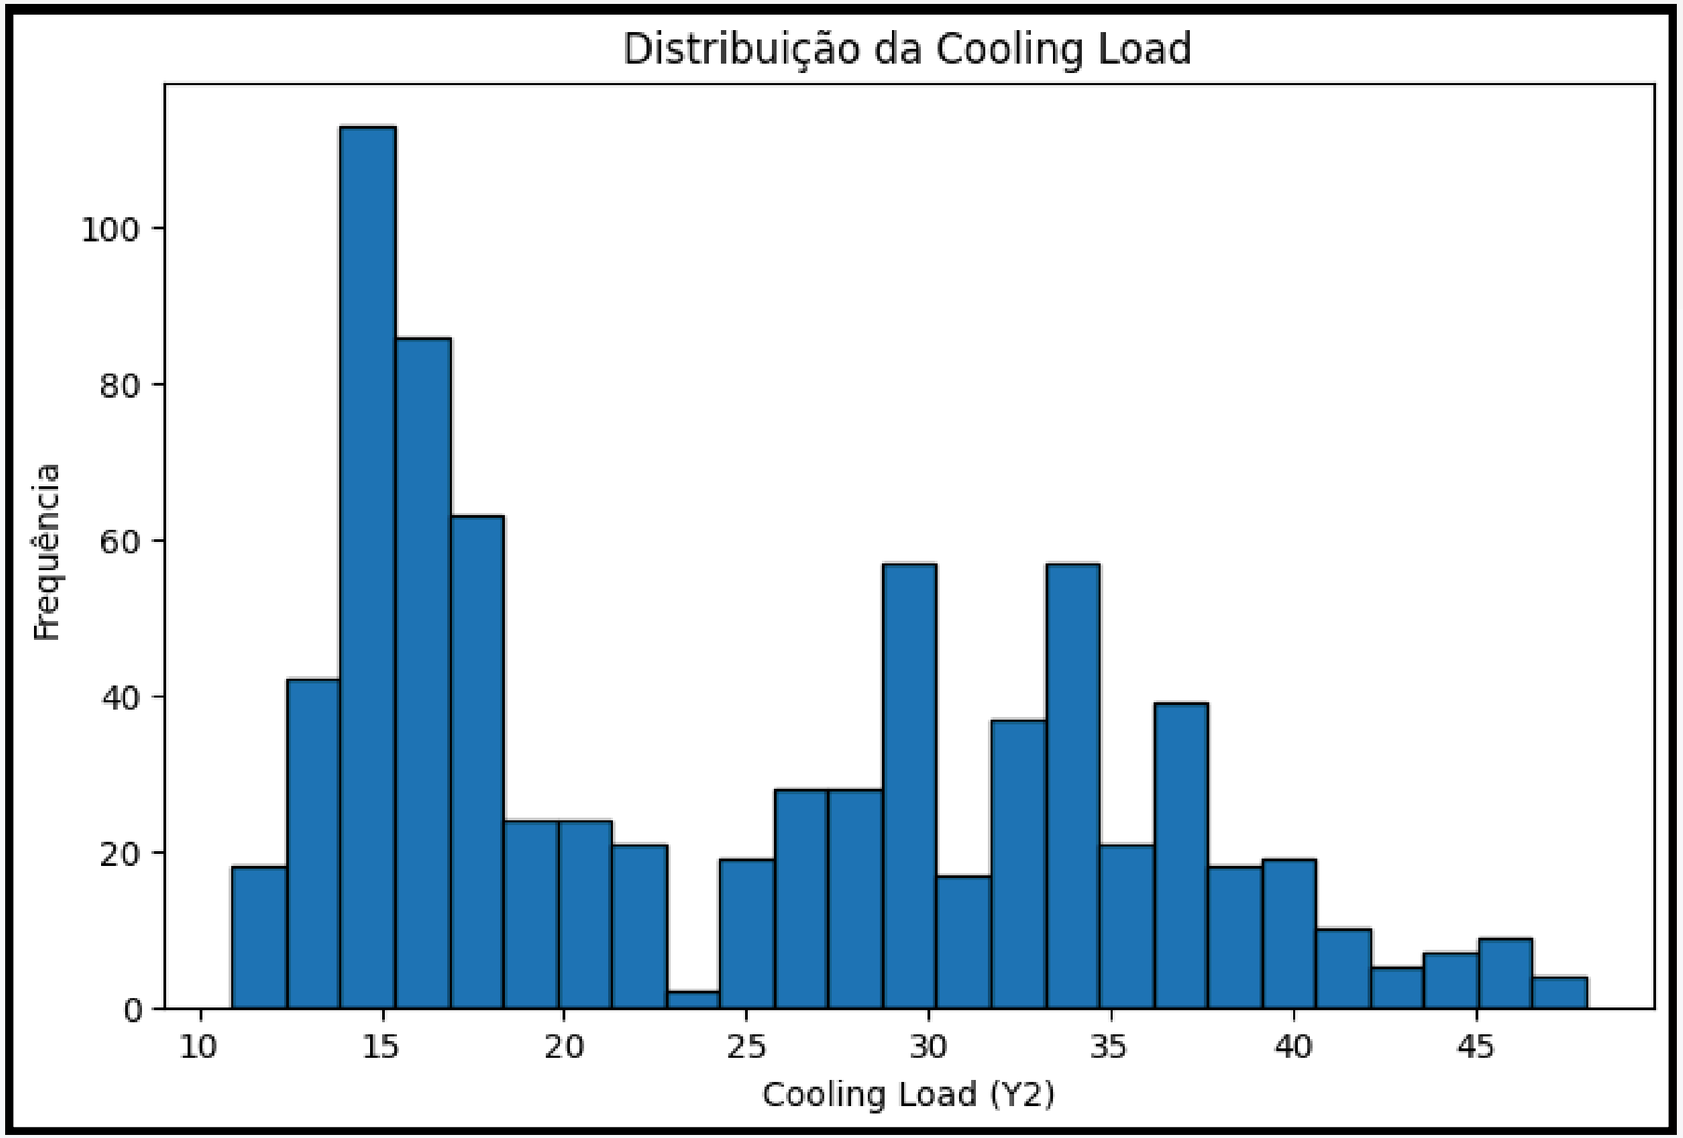
Variável	Significado	Tipo Estatístico
X_1	Compacidade relativa	Quantitativa contínua
X_2	Área de superfície	Quantitativa contínua
X_3	Área das paredes	Quantitativa contínua
X_4	Área do telhado	Quantitativa contínua
X_5	Altura total	Quantitativa (apenas 3,5 e 7,0 na amostra)
X_6	Orientação	Categórica (codificada numericamente)
X_7	Área envidraçada	Quantitativa
X_8	Distribuição da área envidraçada	Categórica (codificada numericamente)
Y_1 / Y_2	Heating Load / Cooling Load	Respostas quantitativas contínuas

Nota: A base de dados não apresentou duplicações ou valores infinitos, não exigindo limpeza corretiva.

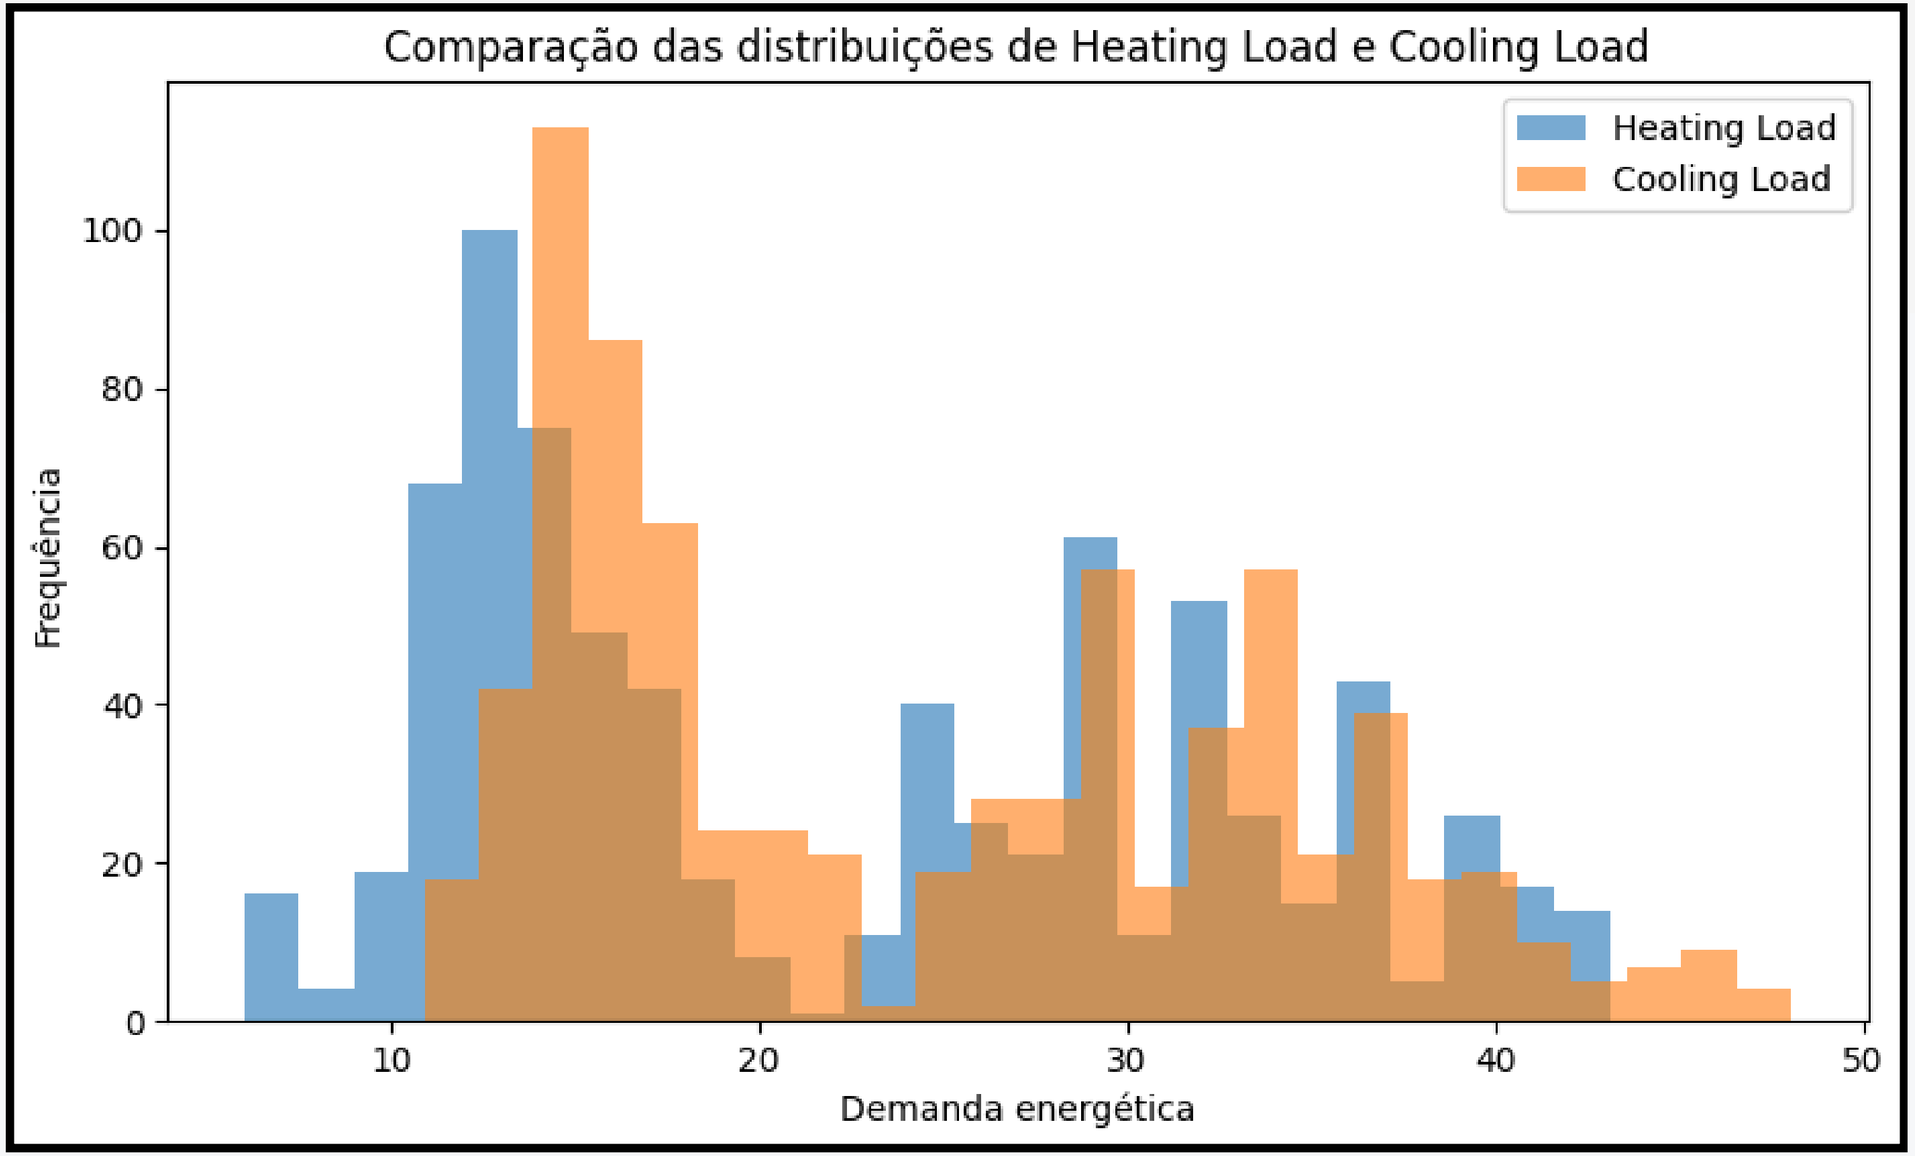
Distribuição Y1



Distribuição Y2



Comparação das distribuições de Y_1 e Y_2



A exploração revelou associações e colinearidade

Correlações Principais

- Entre respostas ($r \approx 0{,}976$)
- X_5 e respostas ($r \approx 0{,}89$)
- X_1 e X_2 ($r \approx -0{,}992$)
- X_4 e X_5 ($r \approx -0{,}973$)

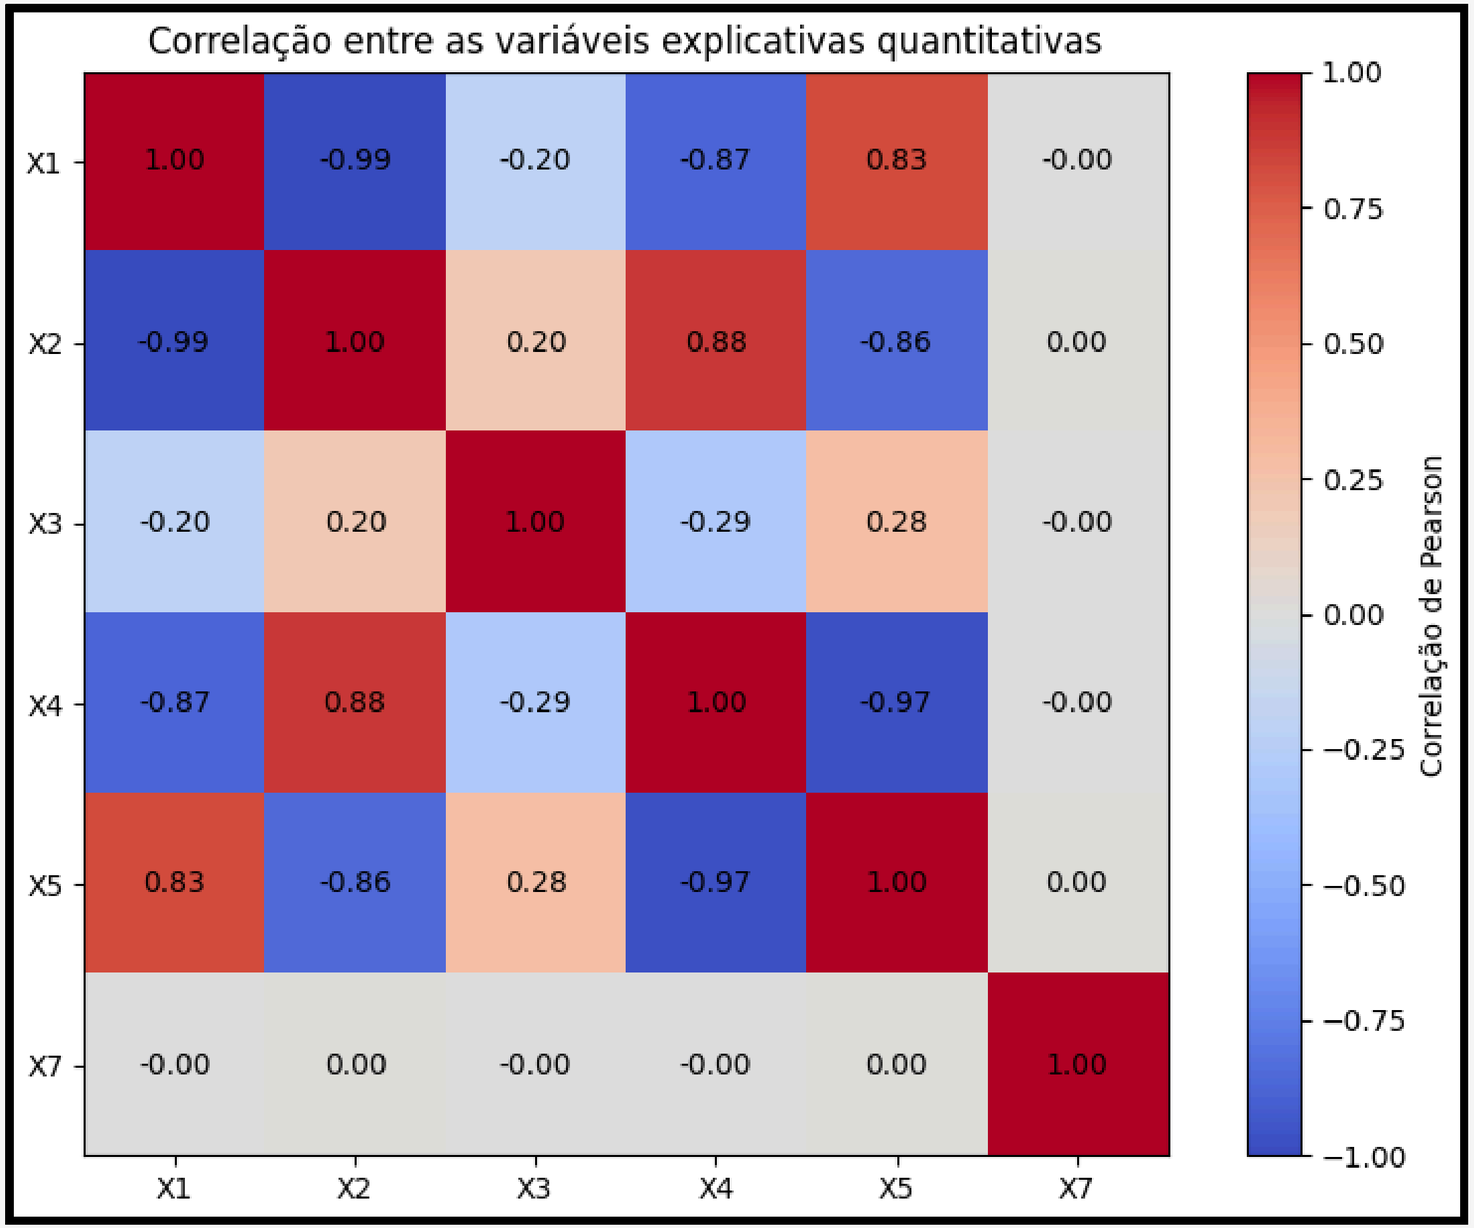
Dependência Linear Perfeita

$$X_2 = X_3 + 2X_4$$

Identidade exata detectada: a inclusão simultânea gera singularidade na matriz de preditores.

> A especificação precisa ser ajustada para evitar multicolinearidade extrema.

Mapa de calor das correlações entre os preditores quantitativos



Modelos de referência: ajuste, parcimônia e VIF

Medida de Qualidade	Modelo 122 — Y_1 (Heating)	Modelo 17 — Y_2 (Cooling)
Preditores selecionados	X_3, X_5, X_7, X_8	X_1, X_5, X_7
R^2 ajustado	0,9178	0,8815
AIC	3819,95	4005,66
BIC	3861,74	4024,23
RMSE Amostral	2,8757	3,2665
VIF máximo	3,927	3,176

Critérios de Seleção: Equilíbrio entre ajuste (R^2), parcimônia (AIC/BIC) e controle da multicolinearidade (VIF).

Status: Estes modelos servem como base para a etapa de diagnóstico. O ajuste amostral é elevado, mas os pressupostos serão testados a seguir.

O que os modelos estimam?

Coeficientes dos preditores; IC de 95% robustos (HC3). Interceptos omitidos para facilitar a leitura.

MODELO 122 | Y_1 — HEATING LOAD

Preditores: X_3, X_5, X_7 e indicadores de X_8

Termo	β estimado	IC 95% (HC3)
X_3	0,0517	[0,0485; 0,0549]
X_5	4,7633	[4,6427; 4,8838]
X_7	16,8483	[15,1559; 18,5408]
X_8 = 1 vs. 0	4,5277	[3,3049; 5,7504]
X_8 = 2 vs. 0	4,4360	[3,2083; 5,6637]
X_8 = 3 vs. 0	4,1830	[2,9572; 5,4088]
X_8 = 4 vs. 0	4,3882	[3,1632; 5,6132]
X_8 = 5 vs. 0	4,1824	[2,9510; 5,4139]

X_8 = 0 é a categoria de referência para os coeficientes de X_8.

MODELO 17 | Y_2 — COOLING LOAD

Preditores: X_1, X_5 e X_7

Termo	β estimado	IC 95% (HC3)
X_1	−30,6074	[−33,9491; −27,2658]
X_5	6,3968	[6,1480; 6,6457]
X_7	14,8180	[13,0436; 16,5923]

LEITURA RÁPIDA

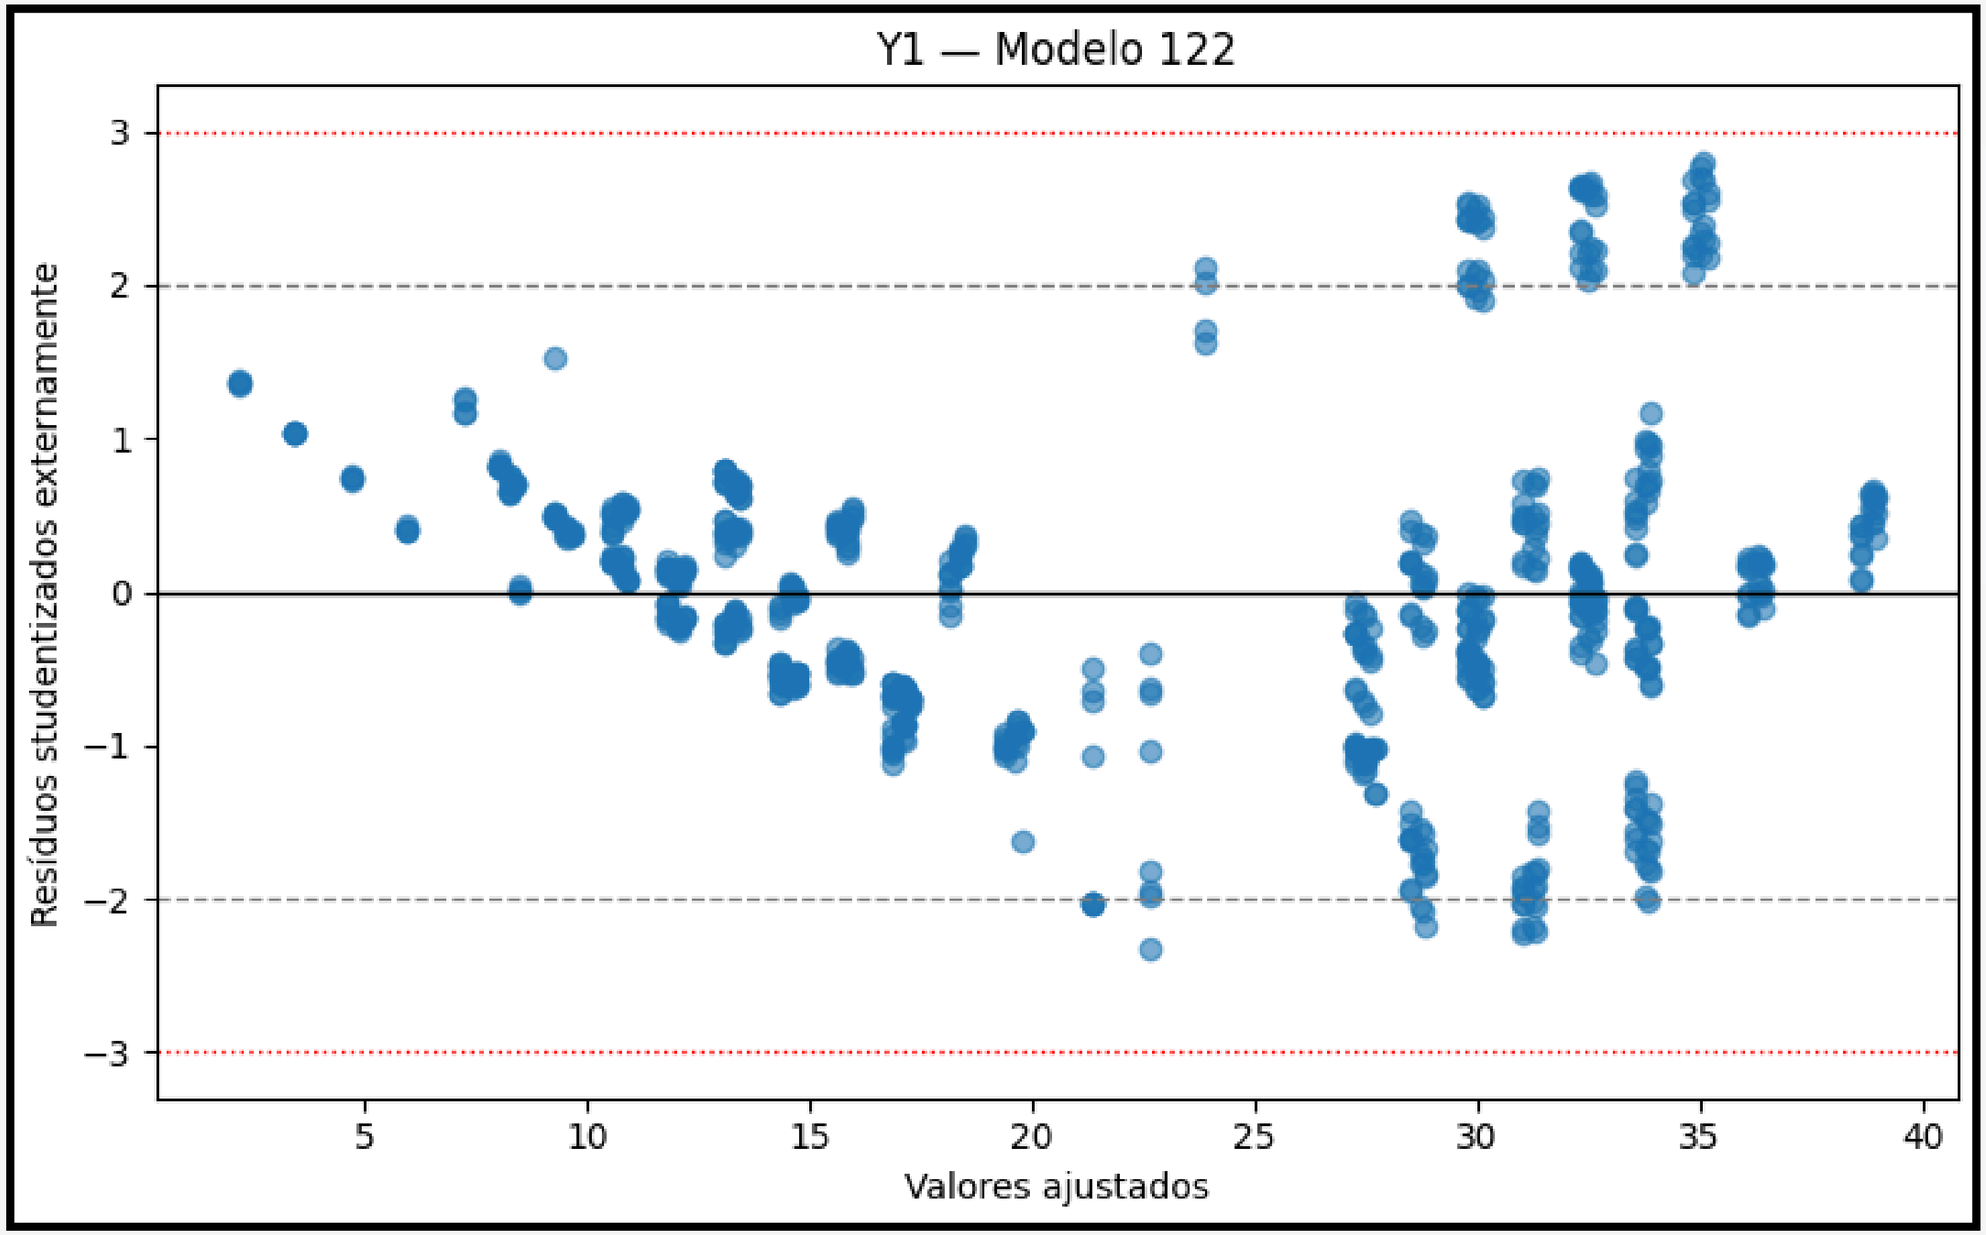
Y_1: X_3, X_5 e X_7 têm coeficientes positivos; os níveis X_8 = 1–5 também ficam acima da referência X_8 = 0.

Y_2: X_1 tem coeficiente negativo; X_5 e X_7, positivos, mantendo os demais preditores constantes.

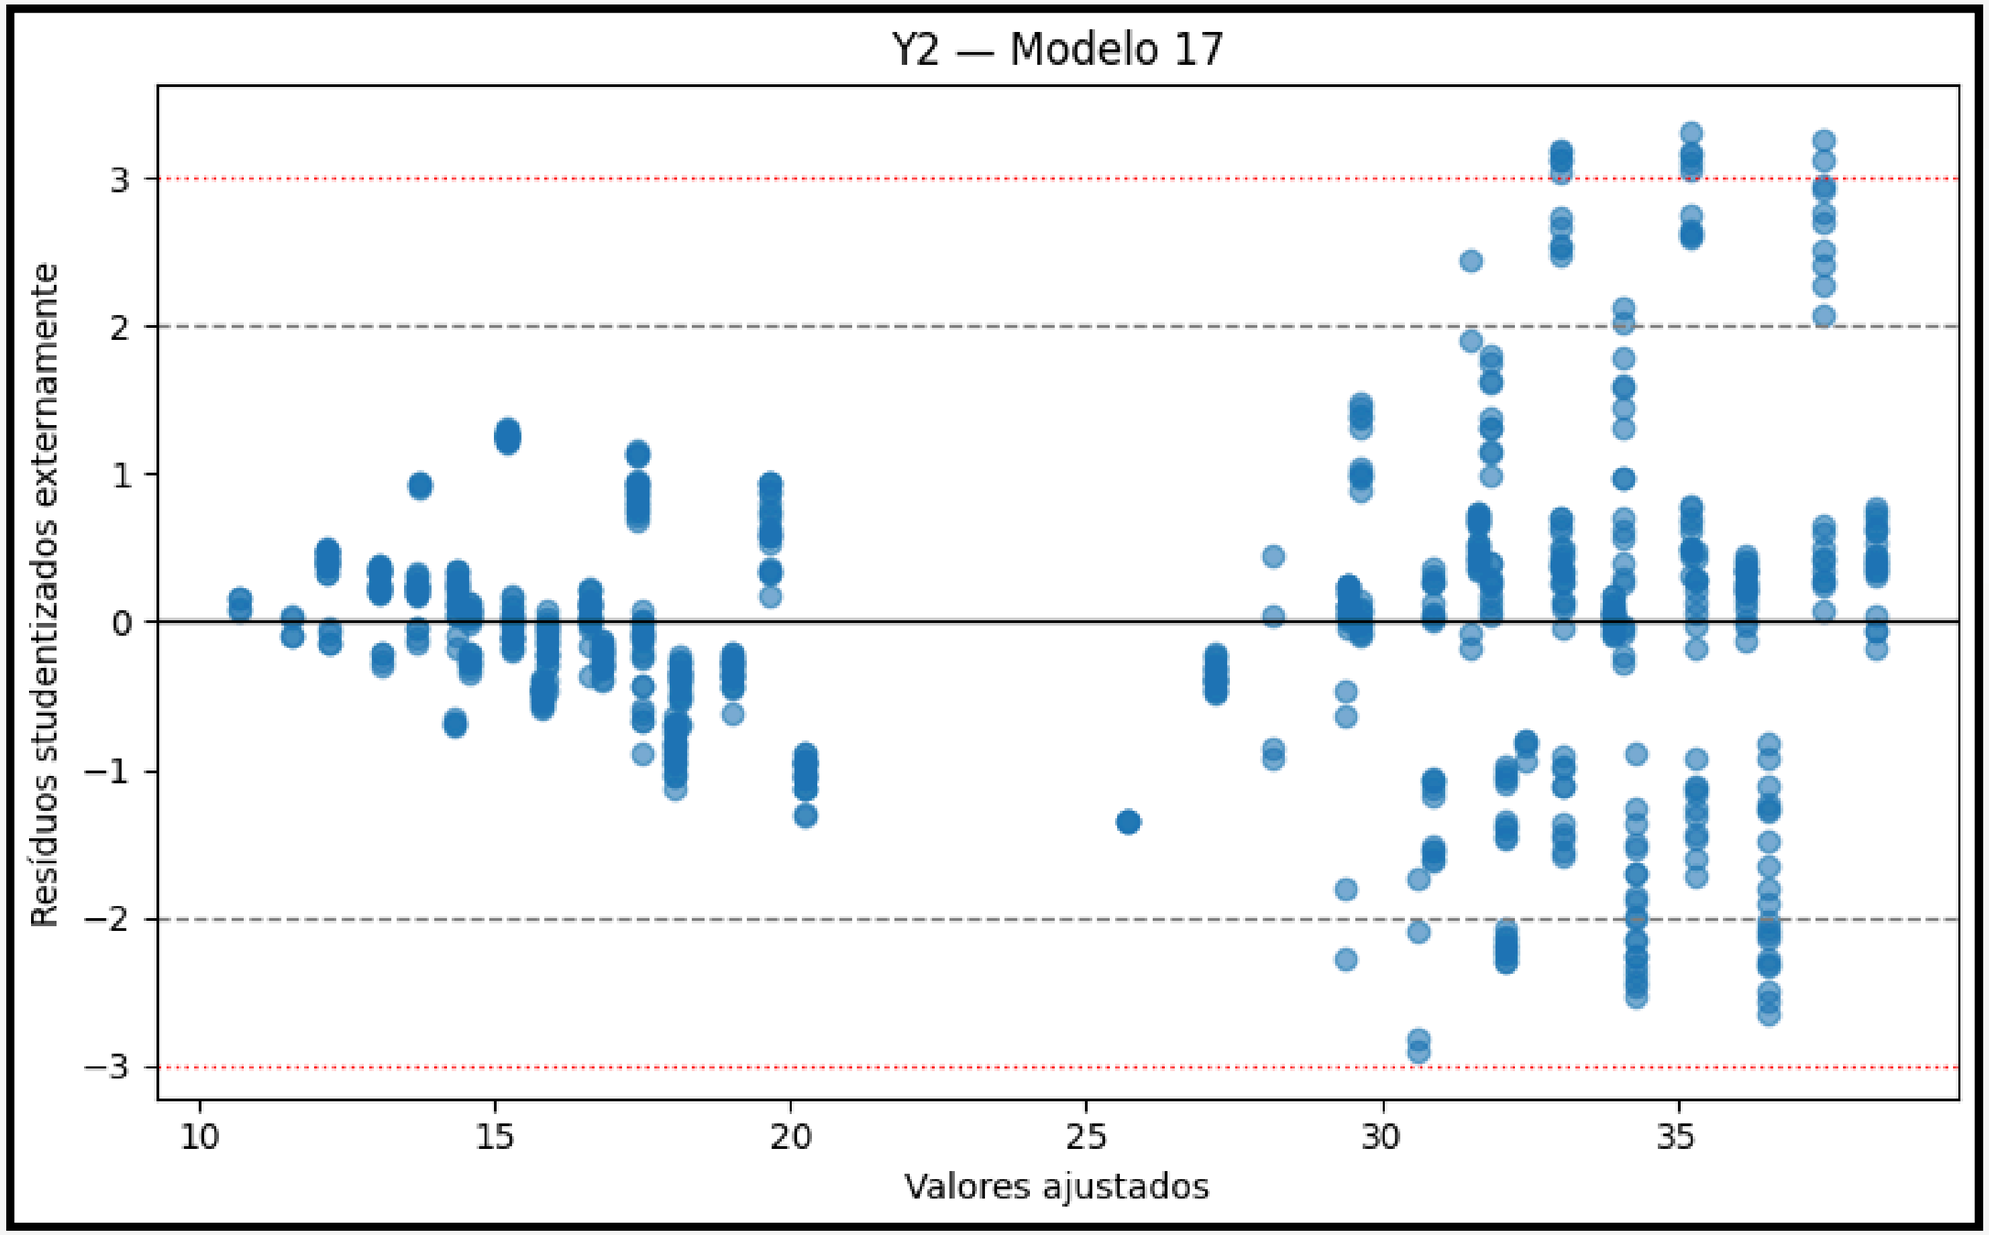
Todos os coeficientes de preditores exibidos: p < 0,001 (HC3).

IC de 95% com covariância robusta HC3. Coeficientes representam associações condicionais, não efeitos causais; o ajuste robusto da inferência não corrige a especificação do modelo.

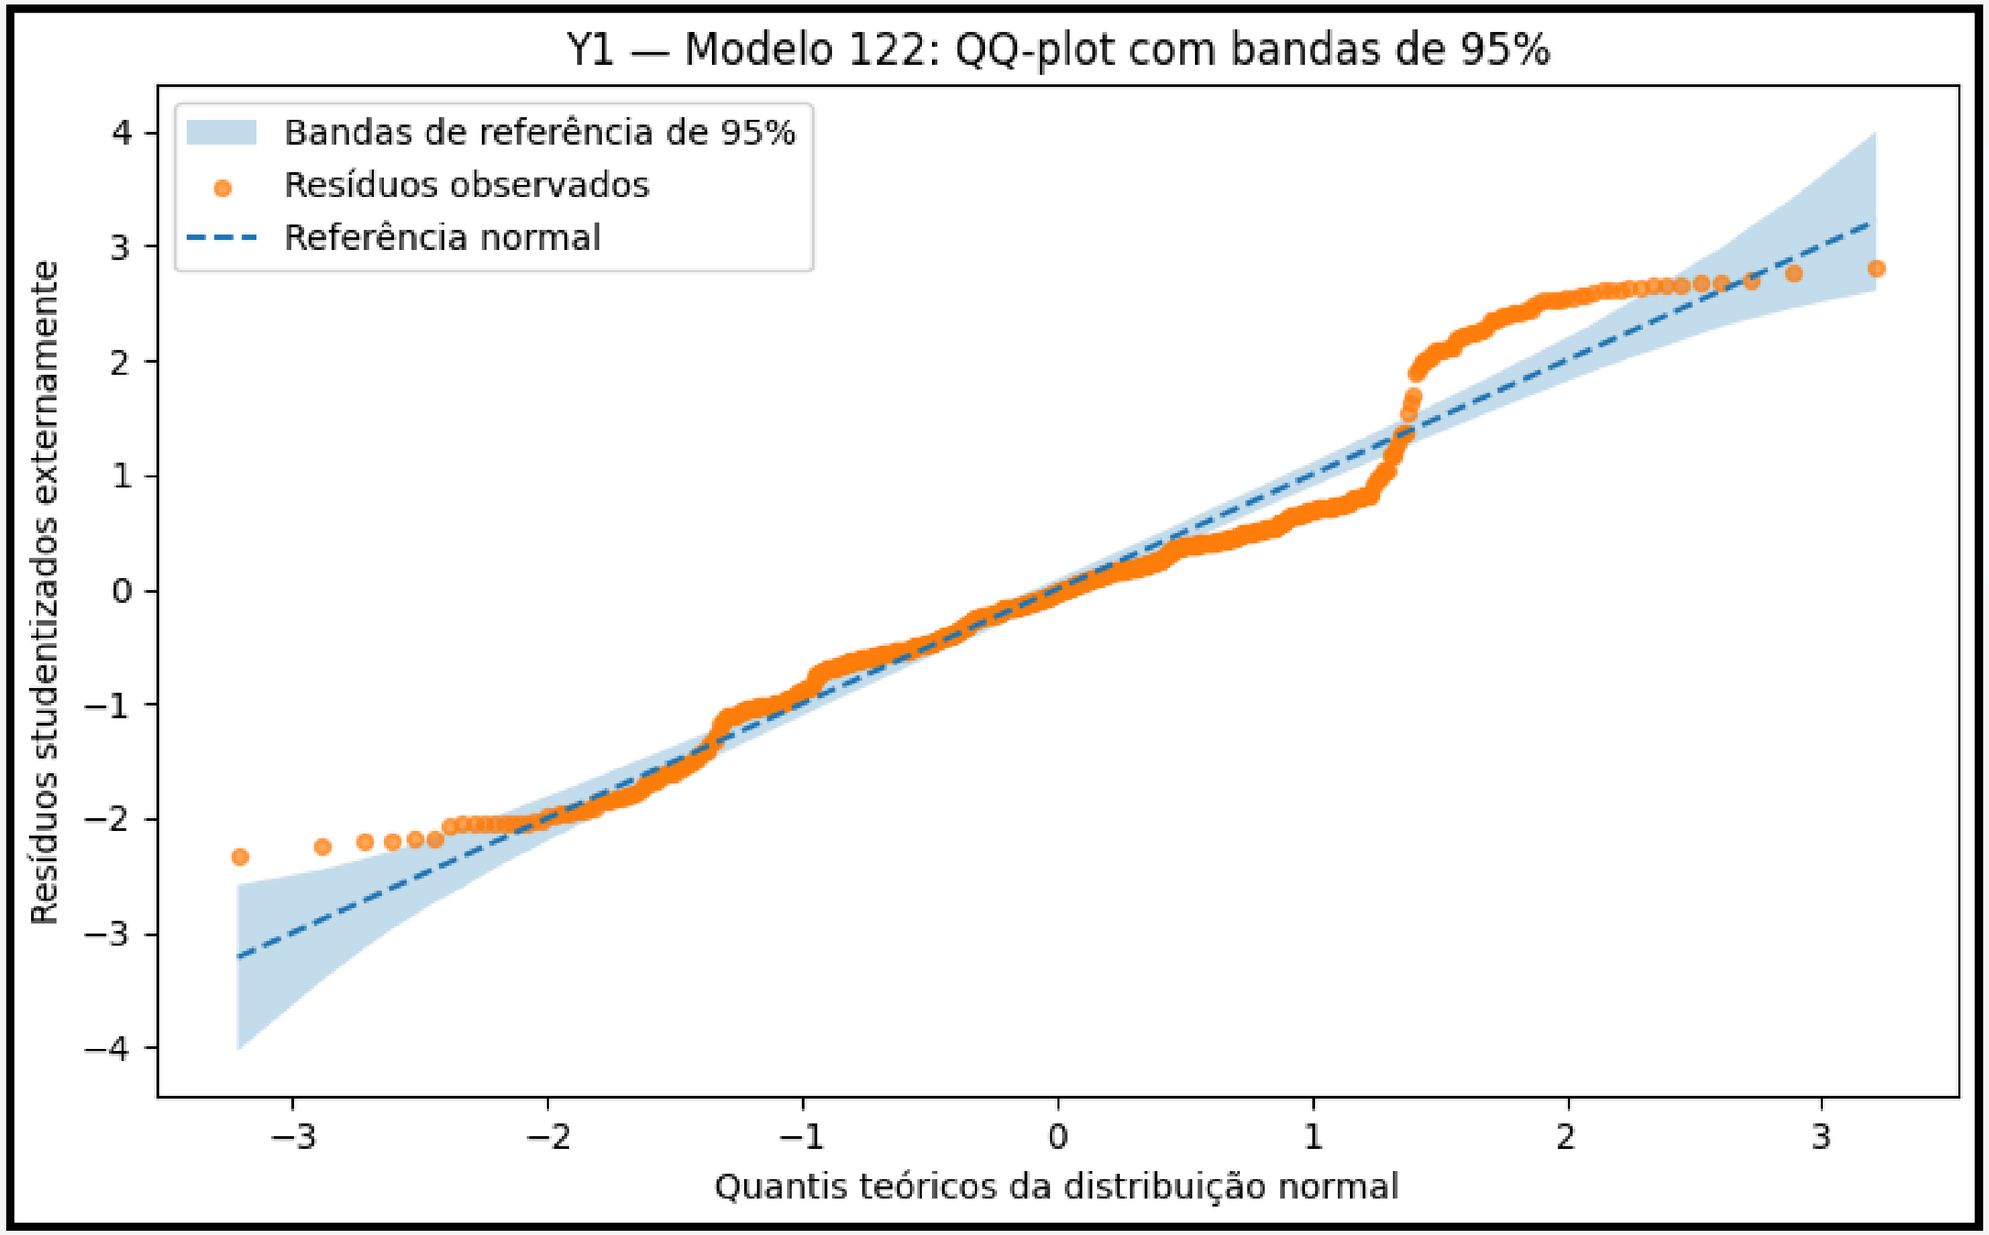
Resíduos x Ajustados Y1



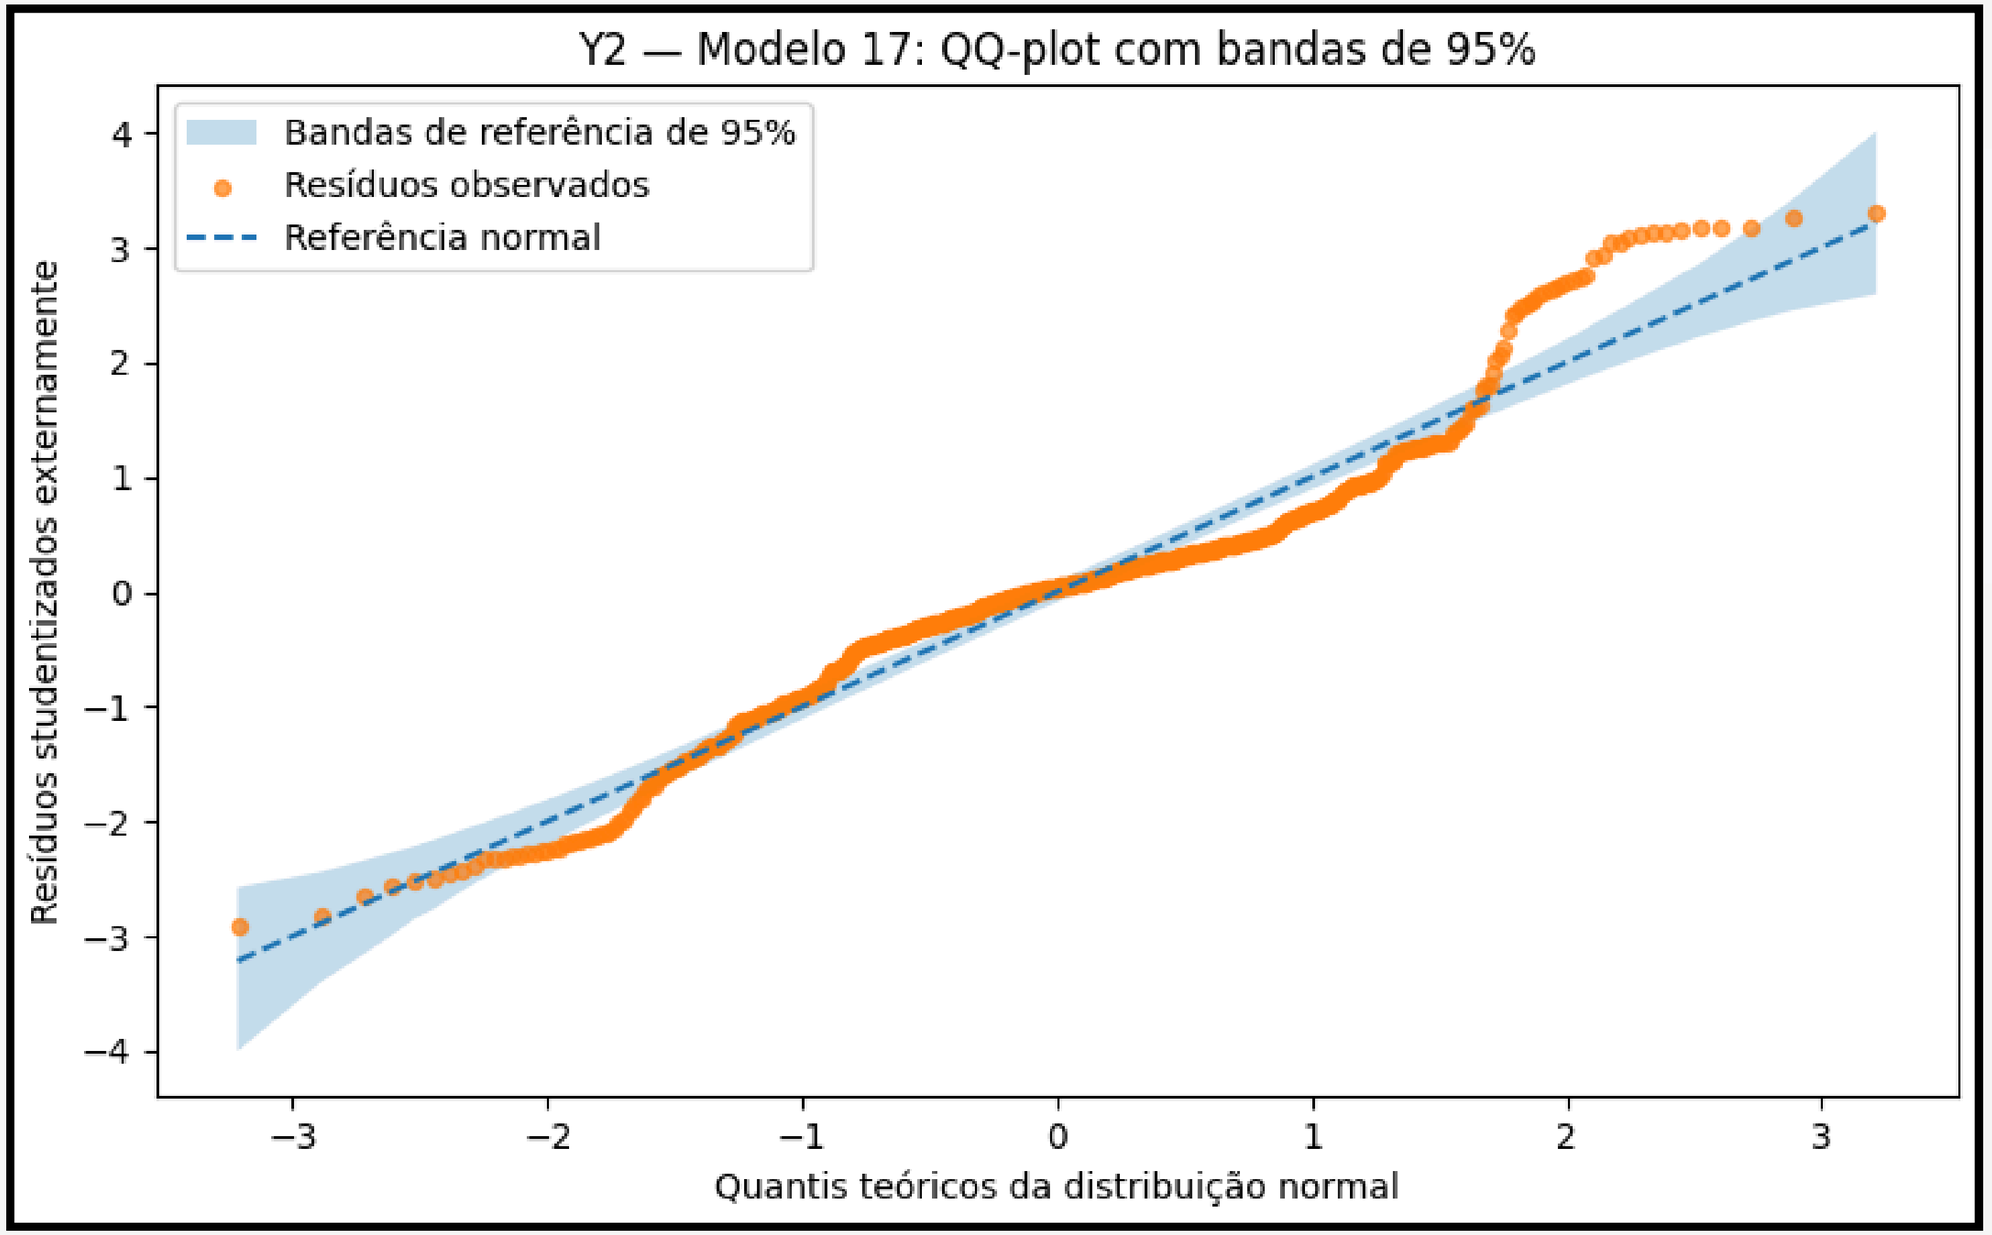
Resíduos x Ajustados Y2



QQ-Plot y1


Y1 — Modelo 122: QQ-plot com bandas de 95%
Bandas de referência de 95%
Resíduos observados
Referência normal
Resíduos studentizados externamente
Quantis teóricos da distribuição normal
4
3
2
1
0
−1
−2
−3
−4
−3
−2
−1
0
1
2
3

QQ-Plot y2


Y2 — Modelo 17: QQ-plot com bandas de 95%
Bandas de referência de 95%
Resíduos observados
Referência normal
Resíduos studentizados externamente
Quantis teóricos da distribuição normal
4
3
2
1
0
−1
−2
−3
−4
−3
−2
−1
0
1
2
3

Os resíduos apontam limitações importantes

Testes Estatísticos (Valor-p)

Diagnóstico	Y_1	Y_2
Breusch–Pagan	4,00e-24	4,33e-32
Jarque–Bera	< 0,001	< 0,001
Ramsey RESET (HC3)	1,69e-42	9,71e-08

A análise visual e os testes rejeitam a homocedasticidade e a normalidade. Os resíduos apresentam padrões agrupados relacionados às configurações das edificações, sugerindo que o modelo aditivo não captura toda a estrutura dos dados.

Conclusão: As evidências indicam inadequação funcional e heterocedasticidade, exigindo cautela na interpretação das inferências e busca por reespecificações.

Casos potencialmente influentes foram investigados

Indicadores de Influência

Indicador	Y_1	Y_2
Leverage acima do limite	12	24
|Resíduos Studentizados Externamente| > 3	0	12
Distância de Cook > 4/n	58	57
DFBETAS acima do limite	142	79

Decisão Metodológica

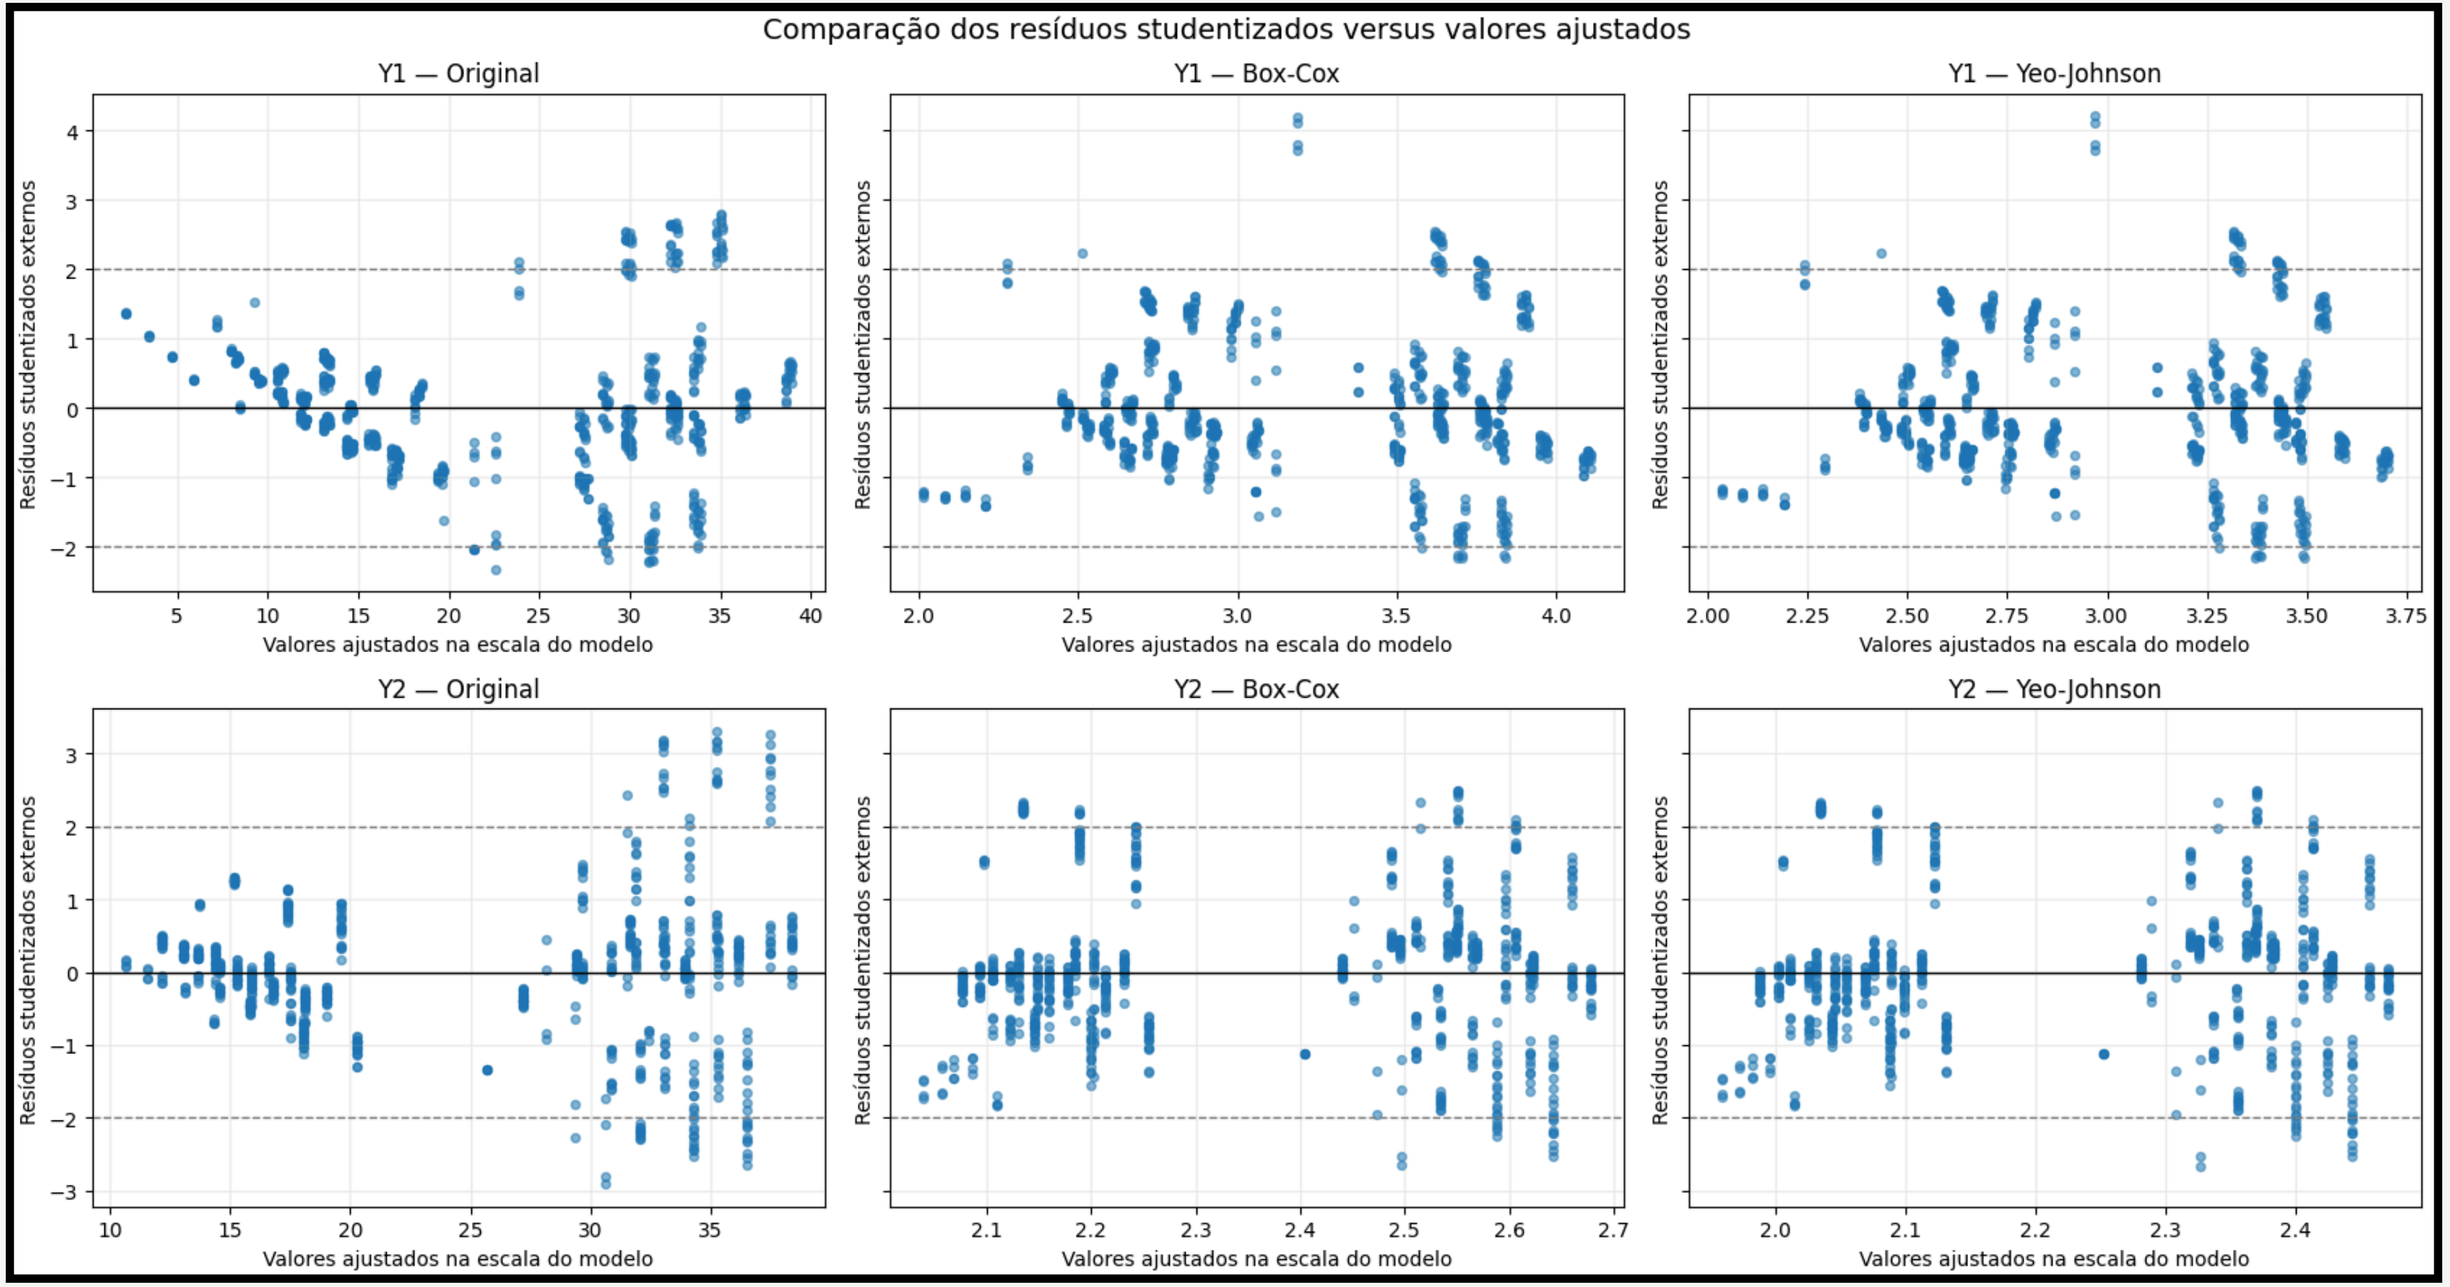
- Limites são exploratórios e não justificam exclusão automática.
- Análise de sensibilidade em 6 observações críticas revelou que os coeficientes mantiveram sinal e estabilidade relativa.
- **Manutenção integral:** Não foi encontrada justificativa física ou erro de registro para excluir observações.
- Os indicadores de influência sinalizam casos que merecem investigação, mas não demonstram, isoladamente, erro nos registros. Como não foi identificada justificativa concreta para exclusão, todas as observações foram mantidas.

Transformar a resposta não resolveu o conjunto dos problemas

Parâmetros Estimados

Resposta	Box–Cox	Yeo–Johnson
Y_1	0,0441	-0,0136
Y_2	-0,1859	-0,2381

Investigou-se se a mudança de escala melhoraria o comportamento dos resíduos. Embora tenha havido melhora parcial na curtose de Y_2, os agrupamentos e padrões de dispersão persistiram, falhando em resolver conjuntamente as violações de pressupostos.


Comparação dos resíduos studentizados versus valores ajustados
Y1 — Original
Y1 — Box-Cox
Y1 — Yeo-Johnson
Y2 — Original
Y2 — Box-Cox
Y2 — Yeo-Johnson
Resíduos studentizados externos
Valores ajustados na escala do modelo

A interação melhora o ajuste, mas aumenta o VIF

Termo de Interação Investigado

$$X_1 \times X_3$$

Compacidade Relativa × Área das Paredes
(Variáveis centradas)

Motivação: Os padrões residuais motivaram investigar se a associação entre a área das paredes e a demanda energética varia conforme a compacidade do edifício. A inclusão deste termo visa capturar essa interdependência não linear. A interação melhora o ajuste amostral, mas não elimina as limitações residuais identificadas pelos diagnósticos.

Indicador	Y1 Aditivo	Y1 Interação	Y2 Aditivo	Y2 Interação
R^2 ajustado	0,9202	0,9272	0,8836	0,8938
AIC	3797,88	3728,37	3992,60	3923,33
RMSE	2,8310	2,7022	3,2346	3,0879
VIF máximo	9,626	12,683	9,626	12,683

O termo de interação apresentou alta significância estatística ($p < 0,001$ com erros robustos HC3). Embora melhore as métricas de ajuste, a elevação do VIF para >12 indica um aumento substancial na multicolinearidade.

Conclusões, limitações e próximos passos

Associações e Colinearidade

01

A análise revelou fortes associações entre geometria e demanda, além de uma dependência linear exata entre preditores, que precisou ser considerada na especificação dos modelos.

Ajuste vs. Pressupostos

02

Modelos de referência mostram bom ajuste amostral, mas diagnósticos apontam limitações estruturais que persistem mesmo após transformações.

Complexidade e Interação

03

O termo $X_1 \times X_3$ melhora o ajuste, indicando que a especificação puramente aditiva pode ser insuficiente, apesar do aumento do VIF.

Transparência Metodológica

04

Todas as observações foram mantidas, pois não foram identificadas evidências concretas de erro que justificassem exclusão.

“A melhor especificação entre as avaliadas apresentou ganhos de ajuste, mas a qualidade da modelagem também depende da análise crítica de suas limitações.”